

Datasets do Challenge 1

Desinformação em saúde pública — grupo ClearColors (G04), Turma 2 — Residência em IA, Instituto Eldorado / UnB
Entrega de 18/09/2026

Este documento lista as bases de dados que o grupo pretende usar durante o challenge, com fonte primária, licença e o papel de cada uma no sistema. A seleção não é definitiva: ela reflete a coleta feita em 08/09/2026 e a inspeção dos dados concluída em 18/09/2026, e pode mudar conforme as fases Investigate e Act avançarem.

O recorte do projeto é desinformação em saúde pública, com sub-recorte em vacinação. O produto é um copiloto de verificação que recupera checagens publicadas, ancora toda afirmação em um trecho citado e rastreável até a fonte, e devolve o critério junto com a conclusão. Essa restrição de produto determina o uso das bases: **dataset de rótulo binário é banco de estímulos, nunca alvo de treino de classificador de veredito.**

Visão geral

As bases estão organizadas em três papéis. O núcleo metodológico alimenta a recuperação de evidência e os exemplares de prompt. A base de comparação de exagero fornece a definição operacional de força da afirmação. O banco de estímulos fornece os itens para o teste com usuário.

Dataset	Idioma	Volume	Papel no projeto	Licença
FactCenter / Central de Fatos	PT	11.647 checagens (4.063 no recorte saúde)	Corpus do RAG e itens falsos	CC BY 4.0
FACTCK.BR	PT	1.313 alegações	Fonte auxiliar de checagem	MIT (estrutura)
FakeRecogna	PT	11.903 itens (5.058 saúde e ciência)	Banco de estímulos do teste	não declarada
PUBHEALTH	EN	12.254 alegações	Pool de exemplares few-shot	MIT
FakeHealth	EN	2.296 notícias 22.959 avaliações	Critérios de qualidade jornalística	CC BY 4.0
Scientific Exaggeration (InSciOut)	EN	663 pares	Força da afirmação	repositório dos autores
Med-MMHL	EN	não baixado (4 GB)	Teste de estresse, condicional	CC BY-NC 4.0

Volumes conferidos na coleta própria, não copiados da descrição dos autores.

Links

Para cada base, a fonte primária é o endereço de onde o arquivo foi baixado. O espelho é uma cópia equivalente, registrada quando existe.

Dataset	Fonte primária	Espelho / referência
FactCenter / Central de Fatos	Zenodo, DOI 10.5281/zenodo.5191798	Artigo no JIDM (sem link de dados)
FACTCK.BR	github.com/thiagorainmaker77/FACTCK.BR	Original: github.com/jghm-f/FACTCK.BR
FakeRecogna	github.com/Gabriel-Lino-Garcia/FakeRecogna	—
PUBHEALTH	github.com/neemakot/Health-Fact-Checking	huggingface.co/datasets/bigbio/pubhealth Artigo: arXiv:2010.09926
FakeHealth	github.com/EnyanDai/FakeHealth	Zenodo, DOI 10.5281/zenodo.3606757 Artigo: arXiv:2002.00837
Scientific Exaggeration (InSciOut)	github.com/copenlu/scientific-exaggeration-detection	huggingface.co/datasets/copenlu/scientific-exaggeration-detection Artigo: arXiv:2108.13493
Med-MMHL	github.com/styxsys0927/Med-MMHL	Artigo: arXiv:2306.08871

Detalhamento por base

1. FactCenter / Central de Fatos — corpus principal

11.647 checagens em português de seis agências (Boatos.org 5.523, Lupa 2.574, Aos Fatos 1.679, Fato ou Fake 917, Estadão Verifica 593, Comprova 361), com o texto integral da checagem. O recorte de saúde e ciência tem 4.063 registros e é a base sobre a qual o índice de recuperação foi construído. Licença CC BY 4.0, que permite redistribuição com atribuição.

2. FACTCK.BR — fonte auxiliar

1.313 alegações em português, coletadas via schema ClaimReview de três agências (Aos Fatos, Lupa, Truco). Serve de reforço ao corpus principal. A licença MIT cobre a estrutura e o código do dataset; o texto das checagens continua sendo das agências.

3. FakeRecogna — banco de estímulos

11.903 itens em português, balanceados em 5.951 por classe, sendo 5.058 nas categorias saúde e ciência. O uso previsto é amostragem de estímulo para o teste com usuário, nunca treino. Uma amostra estratificada de 300 itens já foi extraída como ponto de partida.

4. PUBHEALTH — exemplares de prompt

12.254 alegações em inglês com explicação escrita por checador. O grupo usou o release original dos autores (TSV) em vez do loader do HuggingFace: o loader mapeia rótulos por índice, enquanto no TSV os rótulos vêm como texto (*true*, *false*, *mixture*, *unproven*). O dataset não chega ao usuário como texto — ele fornece o formato da explicação, e os exemplos do prompt serão substituídos por casos brasileiros.

5. FakeHealth — critérios de qualidade

2.296 notícias de saúde avaliadas por especialistas do Health News Review, com 22.959 avaliações de critério (pergunta, resposta e explicação). É a base da matriz de confiança do projeto. Os *engagements* trazem apenas IDs de tweets, por política de privacidade da plataforma.

6. Scientific Exaggeration (InSciOut) — força da afirmação

663 pares de comunicado de imprensa e abstract científico, rotulados como *same*, *exaggerates* ou *downplays*, com a força da afirmação dos dois lados. Fornece a definição operacional de exagero usada no prompt. A anotação deriva de Sumner et al. (2014, BMJ 349:g7015) e Bratton et al. (2019), que devem ser citados junto com o dataset.

7. Med-MMHL — uso condicional

Dataset multimodal de desinformação médica gerada por humanos e por LLM. Os dados não estão no GitHub: ficam em um Dropbox de cerca de 4 GB, quase todo imagem. O uso previsto é teste de estresse, e por isso a base ainda não foi baixada — o repositório do grupo guarda o script de download, o apêndice do artigo e a licença.

O que a inspeção dos dados já mostrou

A coleta foi verificada, contada e inspecionada antes desta entrega. Quatro achados já mudaram decisões de projeto e explicam por que a lista acima tem a composição que tem.

- **O problema de idioma é o inverso do esperado.** Nenhuma das três bases em inglês chega ao usuário como texto; elas atravessam como rubrica e vocabulário de critério, que é adaptação validada e não tradução. O tratamento urgente é no corpus em português.
- **O corpus em português está congelado em 2021.** Dos 4.063 registros do recorte de saúde, 54% são de 2020 e 56% mencionam covid; Qdenga, mpox, oropouche e semaglutida têm zero ocorrência. Daí saiu um requisito novo: o sistema precisa distinguir lacuna do acervo de ausência de checagem no mundo.
- **O campo de veredito não é um rótulo.** São 285 valores distintos e seis vocabulários de agência convivendo. O rótulo *boato*, sozinho, cobre 43% do corpus e não gradua nada. Normalizar esse vocabulário é pré-requisito para indexar.
- **Dois defeitos de forma.** O arquivo do corpus é separado por ponto e vírgula e tem quebras de linha dentro do texto: 4.063 registros em 42.197 linhas físicas, que viram lixo silencioso na leitura padrão. E o FACTCK.BR perdeu todas as maiúsculas acentuadas na origem, o que apareceria na tela do usuário, já que o produto cita trechos literais.

O que ainda falta coletar

Dois conjuntos não existem em nenhuma base pública e são trabalho manual do grupo. O primeiro é um conjunto de **itens verdadeiros contra-intuitivos**: agência de checagem só publica o que é suspeito, e o lado verdadeiro do FakeRecogna é notícia comum de portal grande, que o participante acertaria pelo estilo do texto. A coleta será em fontes de divulgação (Fiocruz, Ministério da Saúde, divulgação científica). O segundo é um conjunto de **itens-armadilha** com evidência ambígua, construídos caso a caso sobre casos reais, para medir se a pessoa mantém o julgamento crítico quando o sistema erra.

Pendências de licença

A verificação nas fontes primárias, feita em 18/09/2026, confirmou MIT para o repositório do PUBHEALTH e CC BY 4.0 para o registro do FakeHealth no Zenodo. Resta o FakeRecogna, que **não declara licença** no repositório dos autores. Enquanto isso não se resolver, os derivados dessa base ficam de uso interno do grupo, e o repositório público guarda apenas o script que os reconstrói. A pendência é sobre publicar, não sobre usar.

Onde está o material

O pacote de datasets, com inventário, contagens, checksums SHA-256 e os derivados já prontos para uso, está no repositório do grupo. O portfólio de pesquisa, incluindo a página de achados que resume esta entrega, está publicado como site.

Repositório: https://github.com/samarawwleticia/challenge1_fakenews_g04

Portfólio: https://samarawwleticia.github.io/challenge1_fakenews_g04/

Próxima entrega: requisitos funcionais e não funcionais da aplicação, previstos para o início da semana de 21/09/2026.