

Challenge 1 — o que mudou nesta rodada

Grupo ClearColors (G04) · residência em IA, Instituto Eldorado · 10 de setembro de 2026

O que tem neste documento

1. Resumo em cinco linhas
2. A correção de rumo: o sistema pode dar veredito
3. O que descobrimos nos dados (a parte mais urgente)
4. As 12 perguntas que vamos investigar
5. O que foi escrito no repositório
6. O que ainda falta o grupo decidir
7. Como estamos trabalhando

1. Resumo em cinco linhas

- Descobrimos que uma regra que o grupo tratava como intocável — “o sistema não dá veredito” — **não está no enunciado do desafio**. Era interpretação nossa. Foi corrigida, com o motivo registrado.
- Medimos o corpus de checagens que ia alimentar o sistema. Ele está **congelado em 2021**, é 56% covid, e tem **zero** menção a Qdenga, mpox, Oropouche ou Ozempic.
- A pergunta “como traduzir os datasets em inglês?” está invertida: os datasets em inglês **nunca chegam ao usuário**. O problema está no corpus em português.
- Fechamos o backlog de **guiding questions**: 40 candidatas do brainstorming viraram 12, cada uma classificada por *o que responderia a pergunta*.
- Criamos uma fase de trabalho que não existia: **tratar os datasets antes de programar qualquer coisa**.

2. A correção de rumo: o sistema pode dar veredito

O enunciado do desafio diz assim:

Em um mundo com excesso de informação, como distinguir fatos, evidências e opiniões? A IA pode apoiar a investigação da confiabilidade das informações, fortalecendo o pensamento crítico em vez de substituí-lo.

A partir de “em vez de substituí-lo”, o grupo havia escrito no documento de contexto do projeto: “o sistema não emite veredito de verdadeiro/falso como saída principal”.

Essas duas coisas não são a mesma:

Não substituir o julgamento da pessoa	Não oferecer um julgamento
É o que o enunciado pede.	É o que a regra antiga fazia.

O que substitui pensamento crítico é o **veredito nu**: a conclusão sozinha, sem raciocínio e sem fonte, que a pessoa só pode aceitar ou recusar. Um veredito acompanhado do critério e rastreável até a fonte *apoia* a investigação — que é literalmente o verbo do enunciado.

E a regra antiga contrariava o próprio enunciado. O problema declarado na Big Idea é excesso de informação. Segurar a conclusão adiciona atrito a um problema de atrito — e “abandono por atrito excessivo” é uma das nossas próprias métricas de guarda. Quem manda a mensagem quer saber se pode acreditar; segurar a resposta faz a pessoa sair com a versão errada na memória.

O que ficou como inegociável

O enunciado exige duas coisas, e essas continuam valendo com força total:

Exigência	De onde vem
Auditabilidade até a fonte	É o que significa “apoiar a <i>investigação</i> ”. Toda afirmação do sistema tem de ter um trecho citado por trás.
Transferência como métrica principal	É o que significa “ <i>fortalecendo</i> o pensamento crítico”. O que medimos é o acerto da pessoa <i>depois, sem a ferramenta</i> — não a acurácia do sistema.

Também recuperamos algo que tinha se perdido na transcrição: o slide da Essential Question traz três competências nomeadas — **investigar evidências · identificar vieses · construir critérios de confiança**. A do meio não tem cobertura nenhuma no que escrevemos até agora (ver seção 6).

A decisão de fundo não mudou: continuamos construindo um *andaime cognitivo*, não um classificador de fake news. O que mudou é o mecanismo — o veredito vem primeiro, mas nunca sozinho.

3. O que descobrimos nos dados

Esta é a parte que muda trabalho concreto. Abrimos o arquivo que ia ser o corpus do sistema (`factcenter_subset_saude.csv` , 4.063 checagens de saúde em português) e medimos.

3.1 O corpus está velho

Medida	Valor
Registros	4.063
Período coberto	2013 a 2021
Só o ano de 2020	2.188 (54%)
Mencionam covid	2.274 (56%)
Mencionam Qdenga	0
Mencionam mpox, Oropouche ou semaglutida	0 cada

Ou seja: as pautas brasileiras de saúde dos últimos anos simplesmente não estão lá. Se alguém perguntar sobre a vacina da dengue, o sistema responderia “*evidência insuficiente*” — e isso é enganoso, porque **existe** checagem publicada sobre Qdenga. O nosso acervo é que não a contém.

Requisito novo que nasceu daí: o sistema tem de dizer “o nosso acervo não cobre esse período”, que é diferente de “não existe checagem sobre isso”. Confundir as duas coisas ensina a pessoa a desconfiar de tudo, que é exatamente o efeito que queremos evitar.

3.2 O campo de veredito não é um veredito

A coluna que deveria dizer “falso” ou “verdadeiro” guarda uma lista de texto, com **285 valores diferentes**, porque cada uma das seis agências usa o seu próprio vocabulário:

```
"['boato']"                1.744 registros  (43% do corpus)
"['FALSO']"                705
"['fake']"                 371
"['Enganoso']" / "['ENGANOSO']" 218  (a mesma coisa, duas grafias)
"['FALSO', 'VERDADEIRO, MAS']" 3
```

Três problemas nisso:

- **“boato” não gradua nada** e é 43% do corpus. A agência que publica esse rótulo só publica rumor — então tudo lá é suspeito por construção. Se tratarmos `boato` como `falso`, ficamos com um corpus quase inteiramente falso.
- **Só 21 registros em 4.063** são “verdadeiro”. O corpus não consegue nos dar os itens verdadeiros que o teste com usuário precisa — sem eles, o participante aprende a responder “falso” sempre e acerta.

- **587 registros falam de mais de uma alegação** — um deles tem 101 rótulos, porque é um compilado semanal da agência. Um registro não é uma alegação.

3.3 Mas os registros “confusos” são o nosso melhor material

250 registros têm rótulos que se contradizem dentro do mesmo texto:

```
['FALSO', 'SUBESTIMADO', 'VERDADEIRO', 'VERDADEIRO']  
['fato', 'nao e bem assim', 'fake']
```

O impulso é jogar fora o que não cabe numa caixinha. Mas isso é *exatamente* o que a Big Idea pede que o sistema saiba fazer: um texto único onde parte é fato, parte é exagero e parte é falso. Ficaram guardados como conjunto de teste.

3.4 Dois defeitos técnicos que apareceriam na tela do usuário

Defeito	Consequência
O arquivo usa ; como separador e tem quebras de linha dentro do texto: 4.063 registros em 42.197 linhas físicas.	Quem abrir com as configurações padrão recebe dados embaralhados <i>sem aviso de erro</i> . Aconteceu comigo na primeira tentativa.
O arquivo do FACTCK.BR perdeu todas as letras maiúsculas com acento . Está gravado Sistema nico de Saúde — o Ú foi apagado.	Como o produto cita trechos literais da fonte, esse texto quebrado apareceria para o usuário. A causa é o filtro de caracteres do script de atualização, que só permite acentos minúsculos.

3.5 A pergunta do idioma estava invertida

A dúvida era: “*como traduzir os datasets em inglês, se nossos usuários são brasileiros?*”

Resposta: **não traduzir**. Nenhum dos três datasets em inglês chega ao usuário como texto. Eles são ferramenta de bastidor:

Dataset	Para que serve de verdade	Como atravessa para o português
PUBHEALTH	exemplos que ensinam o modelo a redigir a explicação	Substituindo por casos brasileiros. Um exemplo traduzido ensina o modelo a escrever <i>como tradução</i> .
FakeHealth	a lista de critérios de qualidade de uma notícia de saúde	Adaptando os critérios e testando contra casos brasileiros. Critério que não separa nenhum caso nosso sai da lista.
InSciOut	a definição de “força da afirmação” (estudo × manchete)	O conceito atravessa direto; os exemplos vêm dos nossos casos.

O que precisa cruzar a fronteira de idioma é **vocabulário de critério**, e isso é adaptação, não tradução. O trabalho urgente está no corpus em português — o único que chega ao usuário como texto, e o que está

com problema.

4. As 12 perguntas que vamos investigar

O brainstorming produziu cerca de 40 perguntas espalhadas pelos cinco quadros. O critério do grupo é que uma *guiding question* tem de ser pesquisável, não pode ter resposta sim/não, e tem de mudar alguma decisão do projeto. Fechamos em **12**.

A novidade foi classificar cada pergunta por **o que responderia ela**. Sem isso, a lista mistura coisas que exigem trabalhos completamente diferentes:

Classe	Significa	Qtd.
dados	Respondemos analisando os datasets que já temos (cada uma nomeia o arquivo)	5
literatura	Respondemos lendo trabalhos publicados, sem coletar dado novo	3
usuario	Só o teste com participantes responde	4
fechada	Já respondida por decisão que tomamos — sai da pesquisa	10
fundida	Era a mesma pergunta de outra, com palavras diferentes	6
descartada	Não passa no critério de qualidade (com motivo escrito)	12

As **quatro que abrem a fase Investigate** (alto impacto e alta incerteza):

	Pergunta	Como responder
GQ-02	Como distinguir alegação falsa de alegação verdadeira exagerada ou fora de contexto?	dados (InSciOut + FACTCK.BR)
GQ-03	Que sinais de qualidade de evidência dá para extrair de um texto de divulgação, e quando é preciso ir ao estudo original?	dados (FakeHealth)
GQ-04	Como o sistema deve se comportar quando a pauta é mais nova que o acervo, ou quando a fonte oficial mudou de posição?	dados (cobertura do corpus)
GQ-09	Quais critérios as pessoas realmente usam para decidir se acreditam, e onde esses critérios falham?	teste com usuário

Três coisas que a triagem revelou

- **A pergunta mais importante nunca tinha ido ao quadro.** A GQ-04 estava anotada no nosso próprio documento de decisões desde o primeiro dia — *“o consenso se move; tratar fonte oficial como verdade atemporal ensina obediência, não avaliação”* — e nenhum post-it a registrou. Foram os dados que a trouxeram de volta.

- **Uma das evidências que pedimos não existe.** O quadro Problema pedia três números para justificar o projeto: volume de checagens, *tempo entre publicação e desmentido*, e alcance. Só o volume é obtenível. O tempo exigiria a data em que o boato começou, que o corpus não guarda — ele só tem a data da checagem. O alcance exigiria dados do Twitter/X, hoje inviáveis.
- **Achamos um requisito sem definição.** Nossa especificação manda o sistema escolher “a alegação de saúde de maior risco potencial” quando a mensagem tem várias — e *o que é risco* não está definido em lugar nenhum. Virou a GQ-08.

O backlog completo, com as 12 perguntas, a matriz de priorização e o motivo de cada descarte, está no site do portfólio em **Fase Engage → Guiding Questions**.

5. O que foi escrito no repositório

Trabalhamos com *changes*: pacotes de planejamento que dizem por que um trabalho existe, quais decisões foram tomadas, o que o resultado tem de satisfazer, e quais são as tarefas. Hoje são três, um por fase.

Change	Fase	Tarefas	O que cobre
add-engage-desinformacao-saude	Engage	4 de 25	forense de casos, matriz de confiança, guiding questions
add-tratamento-datasets-ptbr	Investigate	0 de 33	novo — arrumar os datasets antes de programar
mvp-copiloto-verificacao	Act	0 de 31	o produto: 6 capacidades, do veredito à acessibilidade

O change novo do Investigate tem quatro capacidades:

Capacidade	Resolve
normalizacao-rotulos	Ler o arquivo direito, interpretar o campo de veredito, mapear os seis vocabulários das agências, e decidir o que fazer com os registros de múltiplas alegações.
integridade-textual	Garantir que o trecho citado é idêntico ao original, reprovar arquivo com letra faltando, e corrigir a causa no script de atualização.
frescor-corpus	Declarar o que o acervo cobre, e definir o que o sistema diz quando a pauta é mais nova que ele.
adaptacao-criterios-en	Fazer os instrumentos em inglês atravessarem para o português por adaptação validada.

Ordem importa: este change *bloqueia* as primeiras seis tarefas do produto. Indexar o corpus antes de normalizar joga o problema de rótulo para dentro do índice, onde tirar fica caro.

Também nesta rodada

- Limpamos o site do portfólio. A navegação apontava para 30 páginas de *outro* projeto — Rich Picture, MoSCoW, SWOT, GORE i*, ata de reunião de 2024 — e nenhuma existia. Agora só lista páginas que existem de verdade.
- Corrigimos a rastreabilidade das guiding questions: a especificação mandava associar cada pergunta a um quadro chamado “Sinais & Viabilidade”, que nunca foi criado. O quadro real se chama “Específicas”.
- Anotamos três correções factuais para o portfólio: o PUBHEALTH tem maioria *verdadeira* (~52%), não falsa; o FakeHealth tem **20** perguntas em dois conjuntos, não 10; e todos os achados do corpus entram como ressalvas.

6. O que ainda falta o grupo decidir

Decisão pendente: “identificar vieses”

É uma das três competências nomeadas no enunciado, e **nenhuma das 14 capacidades a cobre**. O nosso catálogo de técnicas trata de *técnica retórica do texto* (“cura milagrosa”, “manchete exagerada”), que é outra coisa. Viés é: quem publicou e o que ganha com isso, conflito de interesse da fonte, e o viés de confirmação de quem lê — este último é o mais difícil e o mais central para “fortalecer o pensamento crítico”.

Duas saídas: virar requisito, ou sair declaradamente do escopo com justificativa escrita. **Minha recomendação é a primeira** — deixar de fora enfraquece justamente o argumento de que o produto fortalece em vez de substituir.

Questões já registradas, esperando decisão

Questão	Por que travou
Canal: WhatsApp ou web?	Muda a arquitetura, não só a tela. Se a mensagem chega no WhatsApp e a verificação mora em outro app, a maioria não faz a travessia.
Quais 6 a 8 técnicas entram no catálogo	Dá para fechar lendo umas cem checagens do recorte de saúde.
Qual dos dois conjuntos de critérios do FakeHealth adotar	São 20 perguntas em dois conjuntos; ou escolhemos um, ou mapeamos à mão.
De onde vêm os itens verdadeiros do teste	Nenhum dataset baixado tem. É coleta manual: Fiocruz, Ministério da Saúde, divulgação científica.
Sub-recorte dentro de saúde	Vacinação, doença crônica ou suplementos.

7. Como estamos trabalhando

Regra central: **nada entra no repositório sem um *change* que o cubra**. Código, dataset, documento ou entregável. Ficam de fora typo, formatação e configuração de ferramenta.

1. Explorar	entender o problema; nada é escrito ainda
2. Propor	escrever os quatro artefatos do change
3. Validar	o validador confere a estrutura
4. Aplicar	executar as tarefas e marcar os checkboxes
5. Promover	a especificação sobe para a pasta definitiva

Uma coisa está pronta quando as **três** acontecem, não duas: tarefas 100% marcadas, validador limpo, e entregável existindo no repositório.

A precedência é **especificação > tarefas > código**. Quando divergem, a gente atualiza o change — nunca ajusta a especificação para caber no que já foi feito.

Aprendizado desta rodada: o validador confere estrutura, não coerência. Ele passou limpo enquanto um change contradizia o documento de contexto do projeto em cinco lugares diferentes. Isso só aparece na leitura humana — vale reservar tempo para ela.

Documento gerado em 10/09/2026 a partir do estado do repositório. Detalhes completos em [docs/](#) (site do portfólio) e [openspec/changes/](#).